MC896 - PROJETO 2

EQUIPE: EQUIPE

CLINICAL X TRACTOR INATOR

Natural Language Processing (NLP)

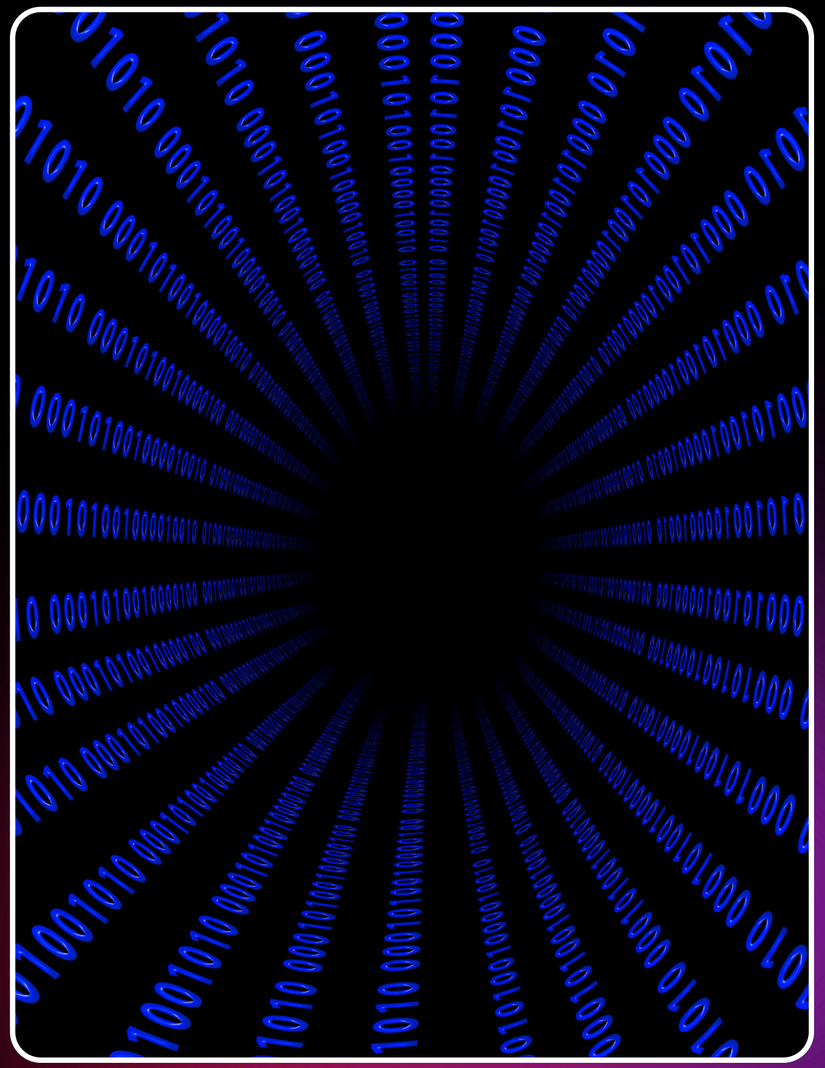

BY

Caio.....248243

Fábio.....247079

Gustavo.....247149

Wallysson.....200061

MC896 - PROJETO 2

OUR TEAM

GUSTAVO

WALYSSON

CAIO

FÁBIO

MC896 - PROJETO 2

EQUIPE

01. CONTEXTO

02. N-GRAMAS

03. MODELOS

04. AUDITORIA

05. CONCLUSÃO

CONTEXTO

01.

MC896 - PROJETO 2

EQUIPE

LIMITES DAS REGRAS

Relato clínico → Regras do P1 → Grafo clínico

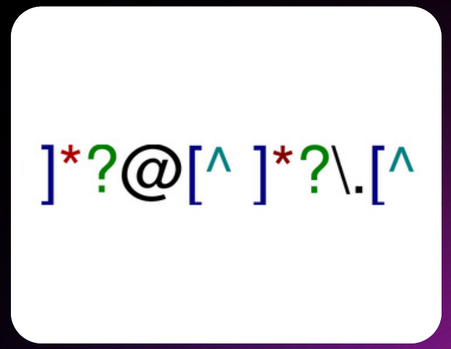

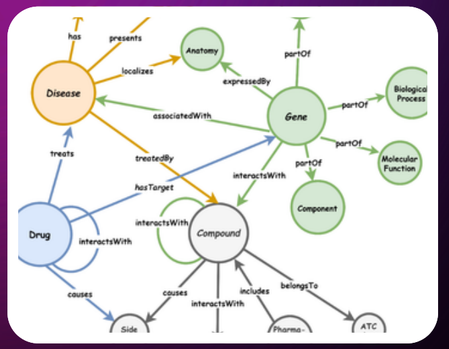

PADRÕES LITERAIS

Só reconhece “revealed” se o verbo estiver na lista.

VOCABULÁRIO FECHADO

Só encontra entidades que estão no gazetteer MeSH.

RELAÇÕES POR TIPO

SUPPORTS e LOCATED_IN são inferidas pela combinação de tipos e coocorrência na sentença.

CONFIANÇA BINÁRIA

Uma aresta existe ou não existe.

MC896 - PROJETO 2

EQUIPE

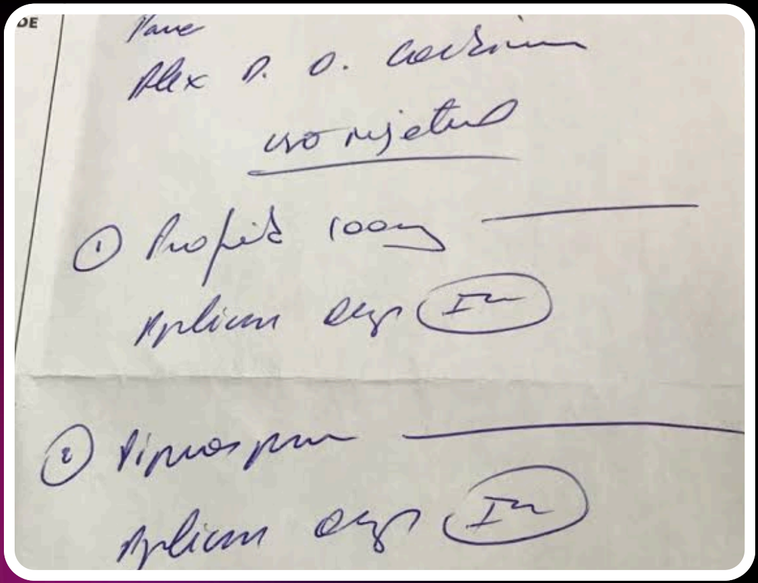

“O aprendizado a partir do próprio texto consegue superar ou complementar as regras do P1?”

Dados: 56 relatos MultiCaRe · 1.465 sentenças · 28.565 tokens

Nossa interpretação: vetores calculados por contagem no próprio corpus (PPMI-SVD, aula nlp-060), nada pré-treinado.

A PERGUNTA *

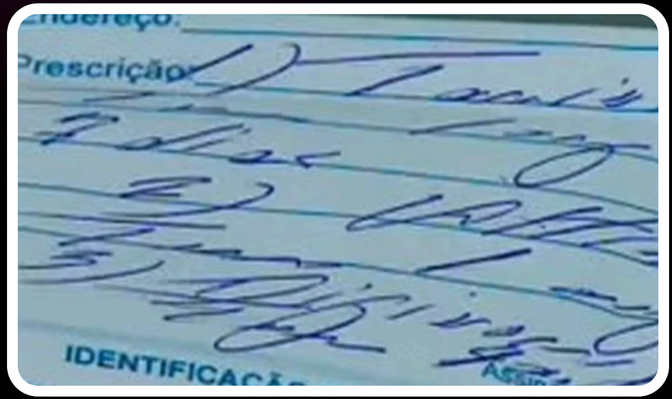

VISÃO GERAL DO PIPELINE

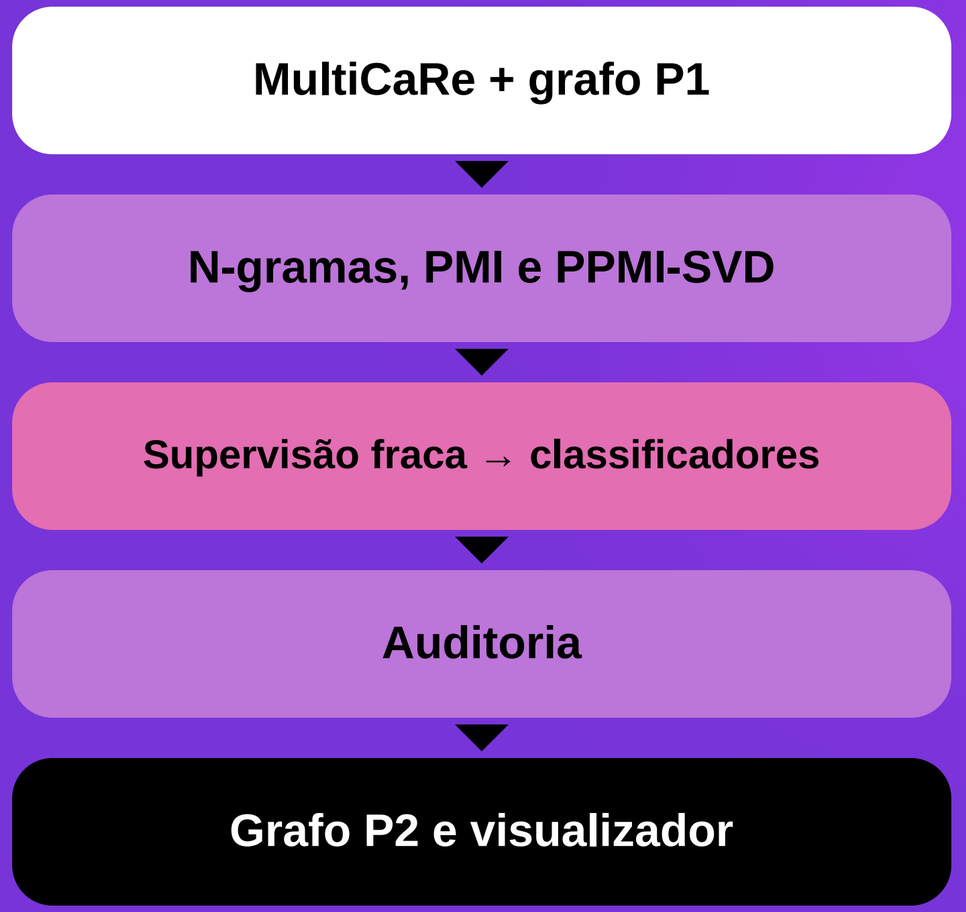

01.

N-GRAMAS

Que conhecimento os n-gramas extraem sem nenhuma regra escrita à mão?

02.

MC896 - PROJETO 2

EQUIPE

COLOCAÇÕES POR PMI

PMI = $\log_2 [P(w_1w_2) / P(w_1)\cdot P(w_2)]$: quantas vezes mais juntas do que o acaso prevê.
Ruído: “isolates from canada”, “mmhg heart rate”.
45 candidatos a entidades novas (OOV), tipados por morfologia de caracteres.
Boas colocações ↓

INTRAUTERINE FETAL DEMISE

LACTATE DEHYDROGENASE

NORMAL SINUS RHYTHM

SHORTNESS OF BREATH

MC896 - PROJETO 2

EQUIPE

SEMÂNTICA

DISTRIBUTIVA

Palavras que se comportam igual.
Exemplo de cluster: revealed / showed / demonstrated [conferir no notebook]
Ponte com Jurafsky: P(dinner | for) ≈ P(lunch | for)

DAS REGRAS AOS MODELOS

Um classificador treinado aprende a reconhecer relações?

03.

MC896 - PROJETO 2

EQUIPE

SUPERVISÃO FRACA

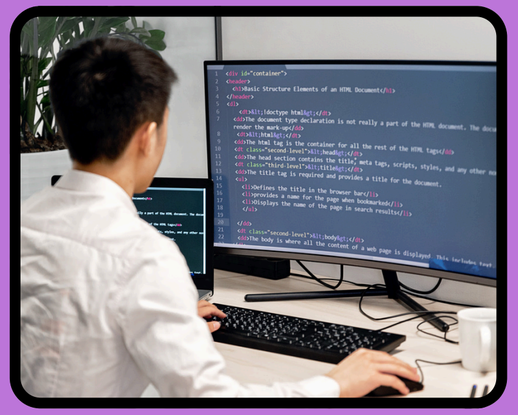

RÓTULOS SILVER

As regras do P1 rotulam os pares; pares sem aresta viram NONE.

CONTEXTO

Features PRE / BTW / POST com gatilhos mascarados; 5 folds por paciente (case_id).

1.529 PARES

NONE 1.103
SUPPORTS 176 · LOCATED_IN 138
TARGETS 80 · REVEALS 24
CONFIRMS 4 · EXCLUDES 4

Ato 1: modelos e representações

Macro-F1 por modelo

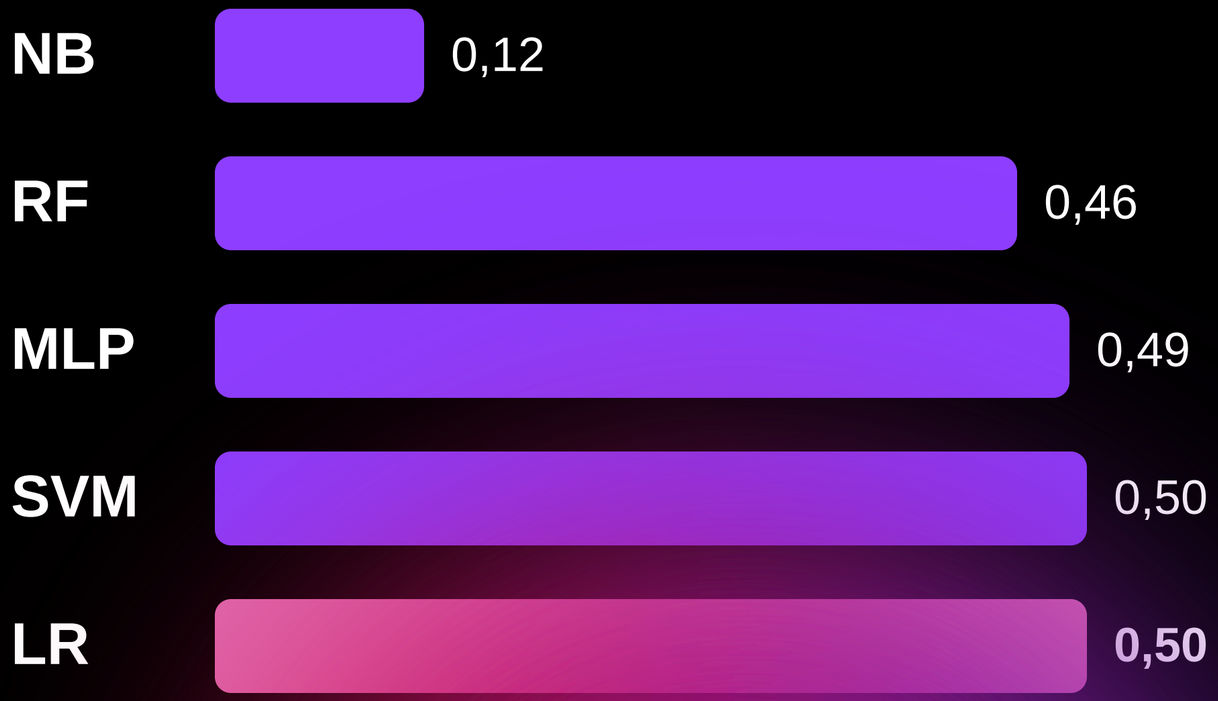

Ablação por n-grama

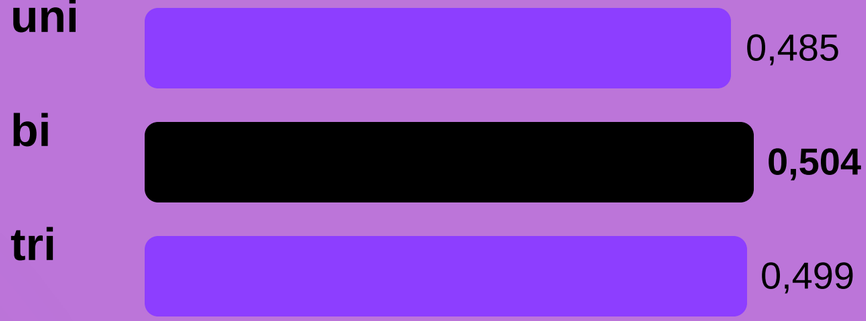

A ablação combina features posicionais; não isola o tamanho do n-grama de palavras.

MC896 - PROJETO 2

ATO 2: IDEIAS DA LITERATURA

EQUIPE

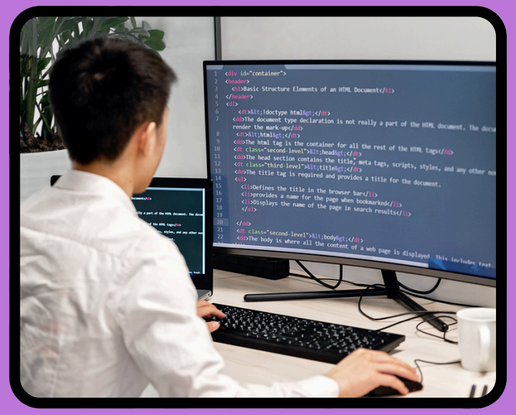

CLUSTERS DE N-GRAMAS

Macro-F1 0,4956
▼ abaixo do baseline (0,4988)

CASCATA: EXISTE RELAÇÃO? → QUAL?

Macro-F1 0,4890
▼ abaixo do baseline (0,4988)

MLP DE TRÊS TORRES

E1 + contexto + E2, interação $h_1 \odot h_ctx \odot h_2$ (~11 mil parâmetros)
Macro-F1 0,5169 ▲ acima do baseline

ATO 3

Mesmo padrão, relações diferentes:
“pain in the chest” → LOCATED_IN
“admitted in December” → sem relação
Features novas: SIG_Diagnosis_TO_Anatomy, DIST_SHORT, SIG__BTW_in
Macro-F1: 0,5385

03.

ENSEMBLE

$P \propto (0{,}55 \cdot P_{cascata} + 0{,}45 \cdot P_{MLP}) \times P_{MeSH}^{0{,}65}$

Precisão 0,566 · Recall 0,693 · Macro-F1 0,617

03.

AUDITORIA

O que o modelo realmente aprendeu?

04.

MC896 - PROJETO 2

EQUIPE

SEM TEXTO?

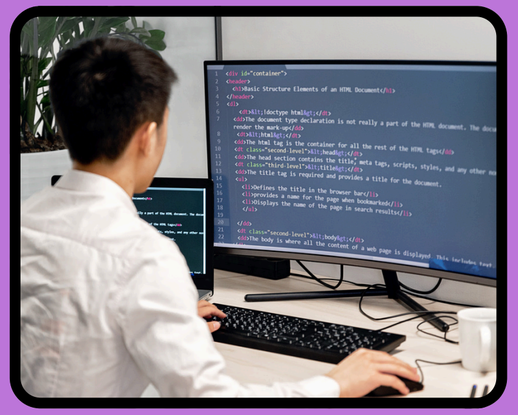

MODELOS DE TEXTO *

LR 0,504
Ato 2 0,522
Ensemble 0,617

SÓ TIPOS *

Sem ler nenhuma palavra:
Só tipos 0,539
Tipados 0,539

83,7% *

dos rótulos são determinados pelo par de tipos.
XAI de uma aresta nova:
sig_examinstance_to_diagnosis,
type_symptomobservation_anatomy

A CAUSA

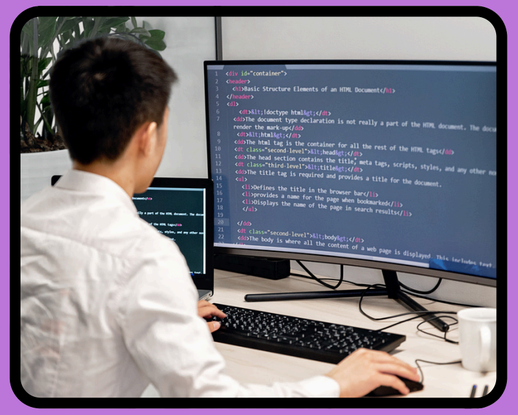

O QUE O MODELO LEU

Par CASPR2 × tomografia.
Caracteres 0–66: “A 49-year-old male presented to our clinic for further diagnostic”

ONDE AS ENTIDADES ESTÃO

~4.300: “...ruled out an autoimmune encephalitis. Due to the CASPR2 antibodies...”
~4.500: “...computed tomography (PET-CT) which showed no indication of a tumor”

SÓ 10 PARES

1.529 de 1.529 pares liam o início do relato; só 10 continham as duas entidades.

GRAFO E CONCLUSÃO

O que foi produzido e como interpretar?

05.

GRAFO P1 VS. P2

Nós: 1.607 → 1.652
Arestas: 3.757 → 3.991 (+234 do ML)
Densidade: 0,00291 → 0,00293 (+0,5%)
RULE_P1 em linha cheia · STATISTICAL_ML em tracejada

05.

Visualizador

a. Linha do tempo com o player sentença a sentença

b. Narrativa sincronizada nos dois sentidos com o grafo

c. Aba de XAI com os pesos β·x reais

Limitações

- Rótulos silver, sem gabarito humano independente
- Corpus pequeno: contagens como C(located) = 4
- Viés do PMI para n-gramas raros; nós OOV não validados
- Macro-F1 instável com classes de 4 exemplos
- Prior e vetores estimados globalmente

Os números medem a concordância com as regras do P1 dentro do nosso protocolo, não a precisão clínica.

Conclusão

01

N-gramas capturam a gramática e as regularidades do texto clínico. [conferir]

02

O rótulo do P1 é, em grande parte, a ontologia: um baseline de tipos é indispensável.

03

Auditar o pipeline revelou o que os números escondiam. [conferir]

GitHub: https://github.com/THdeCamargoJ/mc896-2s2026-equipe

REGRAS FORNECEM ESTRUTURA E RÓTULOS.
N-GRAMAS REVELAM O CORPUS.
ML GENERALIZA QUANDO LÊ O CONTEXTO CERTO.
A AUDITORIA GARANTE QUE OS NÚMEROS SIGNIFIQUEM ALGO.

OBRIGADO!

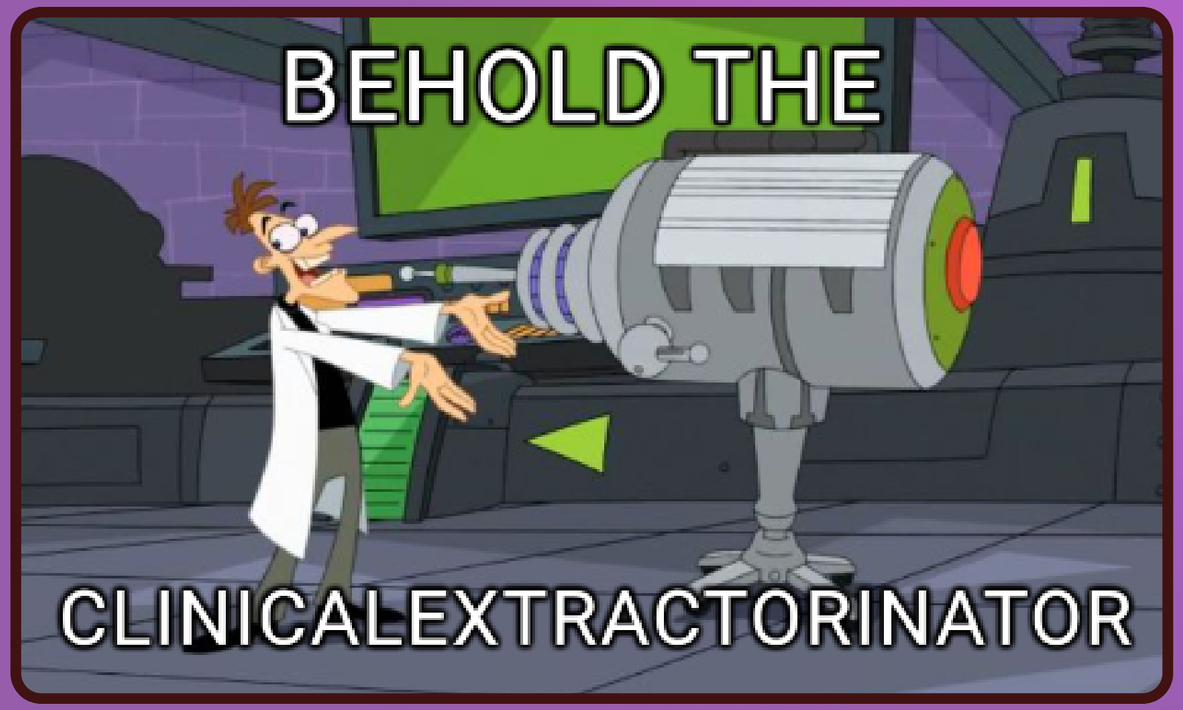

GitHub do projeto:

https://github.com/THdeCamargoJ/mc896-2s2026-equipe

BYE!

CREDITS

This presentation template is free for everyone to use thanks to the following:

Slides Carnival

for the presentation template

Pexels, Pixabay

for the photos

Happy designing!